

Índice

TEORÍA NECESARIA PARA EL PROYECTO	1
1. TEORÍA ELEMENTAL	1
1.1 Variables aleatorias	1
1.2 Procesos estocásticos	2
2. MOVIMIENTO BROWNIANO	3
2.1 Contexto histórico	3
2.2 Distribución gaussiana multidimensional	3
2.3 Proceso de Wiener (definición formal)	3
2.4 Variación cuadrática	3
3. LEMA DE ITÔ	4
3.1 ¿Por qué no funciona la regla de la cadena clásica?	4
3.2 Derivación paso a paso	4
3.3 Interpretación geométrica	5
3.4 Aplicación: solución del GBM	5
3.5 Conexión con el mercado real	6
4. CONCLUSIONES ESPERADAS	6

TEORÍA NECESARIA PARA EL PROYECTO

Objetivo: *Comparar empíricamente trayectorias de precios reales con modelos brownianos geométricos*

1. TEORÍA ELEMENTAL

1.1 Variables aleatorias

De ahora en adelante estaremos trabajando con variables aleatorias. En el caso particular del movimiento browniano, no trabajaremos con una variable, sino con una familia de variables aleatorias — un **proceso estocástico**.

Formalmente, si tenemos un espacio muestral Ω , una variable aleatoria es una función $X: \Omega \rightarrow \mathbb{R}$ cuyo dominio es el espacio muestral. Por ejemplo, al lanzar una moneda equilibrada dos veces, el espacio muestral es $\{CC, CX, XC, XX\}$, y la variable aleatoria “número de caras obtenidas” asigna valores $\{2, 1, 1, 0\}$ respectivamente.

Las variables aleatorias son aplicaciones lineales. Si $H(\omega)$ y $P(\omega)$ describen la altura y el peso de un individuo en una población, su combinación lineal $\lambda H(\omega) + \mu P(\omega)$ también es una variable aleatoria.

También podemos definir subconjuntos condicionados:

$$\{\omega : P(\omega) > 100\} \cap \{\omega : 1.70 < H(\omega) < 1.80\}$$

La composición de variables aleatorias produce variables multidimensionales. Por ejemplo:

$$\varphi(X(\omega), Y(\omega)) = X^2 + Y^2$$

Y la suma parcial de n variables:

$$S_n(\omega) = \sum_{k=1}^n X_k(\omega)$$

Espacio de probabilidad Si tenemos un espacio muestral Ω y su σ -álgebra $\mathcal{J}$ (el conjunto de todos los subconjuntos medibles), una medida de probabilidad P sobre $\mathcal{J}$ cumple los **axiomas de Kolmogorov**:

1. $P(A) \geq 0, \forall A \in \mathcal{J}$
2. $P(\Omega) = 1$
3. Si $A_i \cap A_j = \emptyset$, entonces $P(\bigcup A_i) = \sum P(A_i)$

La tripla $(\Omega, \mathcal{J}, P)$ se denomina **espacio de probabilidad**.

1.2 Procesos estocásticos

Un proceso estocástico es un conjunto de variables aleatorias que dependen del tiempo:

$$\{X_t\}_{t \in [0, T)}$$

definidas sobre un espacio de probabilidad $(\Omega, \mathcal{J}, P)$ con valores en $\mathbb{R}$. Los valores que puede tomar X_t se llaman **estados**. Existen cuatro combinaciones:

	Tiempo discreto	Tiempo continuo
Estado discreto	Cadenas de Markov	Proceso de Poisson
Estado continuo	Series temporales	Movimiento Browniano

1.2.1 Cadenas de Markov En procesos discretos, la **probabilidad de ocupación de estado** es:

$$P(X_n = x_n)$$

La **probabilidad de transición de estado** es:

$$P(X_n = x_n \mid X_{n-1} = x_{n-1})$$

La **propiedad de Markov** establece que toda la historia pasada se resume en el estado inmediatamente anterior:

$$P(X_n = x_n \mid X_{n-1} = x_{n-1}, \dots, X_0 = x_0) = P(X_n = x_n \mid X_{n-1} = x_{n-1})$$

Las probabilidades de transición se organizan en una **matriz de transición** $P \in \mathbb{R}^{k \times k}$, donde $p_{ij} = P(\text{estado } j \mid \text{estado } i)$. El vector de ocupación evoluciona como:

$$\vec{\pi}_{n+1} = \vec{\pi}_n \cdot P$$

2. MOVIMIENTO BROWNIANO

2.1 Contexto histórico

- **1827 — Robert Brown:** observó el movimiento errático de partículas de polen en agua.
- **1900 — Louis Bachelier:** en su tesis *Théorie de la Spéculation* (bajo Poincaré), usó el movimiento browniano como modelo de precios. Primer texto de matemáticas financieras.
- **1905 — Albert Einstein:** dedujo que la densidad $u(t,x)$ de una partícula satisface la ecuación de difusión $\partial u / \partial t = D \Delta u$, con distribución gaussiana.
- **1926 — Jean Perrin:** usó la teoría de Einstein para estimar el número de Avogadro. Nobel de Física.
- **~1923 — Norbert Wiener:** primer modelo matemático riguroso. De ahí el nombre “proceso de Wiener”.
- **~1944 — Kiyoshi Itô:** definió la integral estocástica y el lema que lleva su nombre, resolviendo el problema de que el browniano es continuo pero no diferenciable en ningún punto.

2.2 Distribución gaussiana multidimensional

Una variable $X: \Omega \rightarrow \mathbb{R}^n$ sigue una distribución gaussiana $N(\mu, \Sigma)$ si:

$$P(X \in B) = \int_B \frac{1}{\sqrt{(2\pi)^n \det \Sigma}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right) dx$$

Si todas las variables de un proceso estocástico siguen una ley gaussiana, el proceso es **gaussiano**.

2.3 Proceso de Wiener (definición formal)

Un proceso estocástico $\{W_t\}_{t \in [0,T]}$ es un **movimiento browniano estándar** si:

1. **$W_0 = 0$** casi seguramente.
2. **Incrementos independientes:** para $0 \leq t_1 < t_2 < \dots < t_n < T$, las variables $W_{t_2} - W_{t_1}$, $W_{t_3} - W_{t_2}$, ..., $W_{t_n} - W_{t_{n-1}}$ son independientes.
3. **Incrementos gaussianos:** $W_t - W_s \sim N(0, t-s)$ para $0 \leq s < t < T$.

Propiedades clave: - Trayectorias continuas en todo $[0,T]$. - **No diferenciable en ningún punto** (con probabilidad 1). - La varianza crece linealmente con el tiempo: $\text{Var}(W_t) = t$.

La caminata aleatoria discreta (lanzamientos de moneda) converge al movimiento browniano continuo cuando $\Delta t \rightarrow 0$ (análogo al teorema del límite central).

2.4 Variación cuadrática

Para una partición $\pi = \{t_0, t_1, \dots, t_n\}$ de $[0,T]$:

Variación total de una función f :

$$V_T(f) = \sup_{\pi} \sum_{i=1}^n |f(t_i) - f(t_{i-1})|$$

Para funciones suaves (C^1), esto equivale a:

$$V_T(f) = \int_0^T |f'(t)| dt$$

Pero el browniano **no es diferenciable**, así que su variación total es infinita. En cambio, su **variación cuadrática** es finita:

$$[W, W](T) = \lim_{n \rightarrow \infty} \sum_{i=1}^n (W_{t_i} - W_{t_{i-1}})^2 = T$$

Este resultado — que la variación cuadrática del browniano es determinista e igual a T — es **la razón fundamental por la que el cálculo estocástico difiere del determinista**. En notación diferencial:

$$(dW_t)^2 = dt$$

3. LEMA DE ITÔ

3.1 ¿Por qué no funciona la regla de la cadena clásica?

En cálculo determinista, si $x(t)$ es diferenciable y f es C^1 :

$$df = f'(x) \cdot dx$$

Para el browniano, esto falla por dos razones: 1. W_t no es diferenciable $\rightarrow$ “ dW/dt ” no existe. 2. $(dW)^2 = dt \neq 0 \rightarrow$ los términos de segundo orden **no se cancelan**.

3.2 Derivación paso a paso

Sea X_t un proceso de Itô:

$$dX_t = \mu(t, X_t) dt + \sigma(t, X_t) dW_t$$

Y sea $f(t, x) \in C^{1,2}$ (una vez diferenciable en t , dos veces en x). Queremos encontrar $df(t, X_t)$.

Paso 1 — Expansión de Taylor bidimensional hasta segundo orden:

$$df = \frac{\partial f}{\partial t} dt + \frac{\partial f}{\partial x} dX_t + \frac{1}{2} \frac{\partial^2 f}{\partial t^2} (dt)^2 + \frac{\partial^2 f}{\partial t \partial x} dt dX_t + \frac{1}{2} \frac{\partial^2 f}{\partial x^2} (dX_t)^2$$

Paso 2 — Sustituir dX_t y expandir $(dX_t)^2$:

$$(dX_t)^2 = (\mu dt + \sigma dW_t)^2 = \mu^2 (dt)^2 + 2\mu\sigma dt dW_t + \sigma^2 (dW_t)^2$$

Paso 3 — Aplicar la tabla de multiplicación estocástica:

$\times$	dt	dW_t
dt	0	0
dW_t	0	dt

¿De dónde salen estas reglas? Esto es crítico y merece una explicación detallada:

- **$(dW_t)^2 = dt$** : Esto proviene directamente de la variación cuadrática. Si particionamos $[t, t+dt]$ y sumamos los cuadrados de los incrementos del browniano, el resultado converge a dt (no a 0). Más formalmente, $E[(\Delta W)^2] = \Delta t$ y $\text{Var}[(\Delta W)^2] = 2(\Delta t)^2$, así que cuando $\Delta t \rightarrow 0$, la varianza de $(\Delta W)^2$ desaparece mucho más rápido que su esperanza $\rightarrow (dW)^2$ se comporta como una cantidad determinista igual a dt .
- **$(dt)^2 = 0$** : Orden $(dt)^2$ es infinitesimal de orden superior. En el límite, cualquier término proporcional a $(dt)^2$ desaparece.
- **$dt \cdot dW_t = 0$** : $E[dt \cdot \Delta W] = dt \cdot E[\Delta W] = 0$ y $\text{Var}[dt \cdot \Delta W] = (dt)^2 \cdot \Delta t = (dt)^3 \rightarrow$ desaparece. Es infinitesimal de orden $3/2$, que se anula frente a dt (orden 1).

Paso 4 — Sustituir en $(dX_t)^2$:

$$\underbrace{\mu^2 (dt)^2}_{=0} + 2\mu\sigma \underbrace{dt \cdot dW_t}_{=0} + \sigma^2 \underbrace{(dW_t)^2}_{=dt} = \sigma^2 dt$$

Paso 5 — Sustituir todo en la expansión de Taylor:

Los otros términos de segundo orden también se eliminan: $-\partial^2 f / \partial t^2 \cdot (dt)^2 = 0$ - $\partial^2 f / (\partial t \partial x) \cdot dt \cdot dX_t$ contiene dt^2 y $dt \cdot dW \rightarrow$ ambos 0

Queda:

$$df(t, X_t) = \left[\frac{\partial f}{\partial t} + \mu \frac{\partial f}{\partial x} + \frac{1}{2} \sigma^2 \frac{\partial^2 f}{\partial x^2} \right] dt + \sigma \frac{\partial f}{\partial x} dW_t$$

Este es el lema de Itô. El término $\frac{1}{2}\sigma^2 \partial^2 f / \partial x^2$ es la **corrección de Itô** — no existe en cálculo clásico y es consecuencia directa de que $(dW)^2 = dt \neq 0$.

3.3 Interpretación geométrica

En cálculo clásico, la diferencial de una función compuesta solo depende de la pendiente local (primer orden). En cálculo estocástico, el browniano “fluctúa tanto” localmente que la **curvatura** (segundo orden) de f también contribuye a la diferencial. Si f es convexa ($f'' > 0$), el proceso $Y_t = f(X_t)$ tiene un drift adicional positivo. Si f es cóncava ($f'' < 0$), el drift adicional es negativo. Esto es exactamente lo que ocurre con el logaritmo en la siguiente sección.

3.4 Aplicación: solución del GBM

El precio S_t sigue:

$$dS_t = \mu S_t dt + \sigma S_t dW_t$$

Aplicamos Itô con **$f(S) = \ln(S)$** :

Derivadas: $-\partial f / \partial S = 1/S$ - $\partial^2 f / \partial S^2 = -1/S^2$ - $\partial f / \partial t = 0$

Sustitución en Itô (aquí está la sustitución que pides explícitamente):

$$d(\ln S_t) = \underbrace{\frac{\partial f}{\partial t}}_{=0} dt + \underbrace{\frac{\partial f}{\partial S}}_{=1/S_t} dS_t + \frac{1}{2} \underbrace{\frac{\partial^2 f}{\partial S^2}}_{=-1/S_t^2} (dS_t)^2$$

Ahora sustituimos $dS_t = \mu S_t dt + \sigma S_t dW_t$ en cada término:

Término 1: $(1/S_t) \cdot dS_t = (1/S_t)(\mu S_t dt + \sigma S_t dW_t) = \mu dt + \sigma dW_t$

Término 2: $(dS_t)^2 = (\mu S_t dt + \sigma S_t dW_t)^2 = \sigma^2 S_t^2 dt$ (aplicando la tabla de multiplicación)

Término 3: $\frac{1}{2}(-1/S_t^2) \cdot \sigma^2 S_t^2 dt = -\frac{1}{2}\sigma^2 dt$

Resultado:

$$d(\ln S_t) = \left(\mu - \frac{1}{2}\sigma^2\right) dt + \sigma dW_t$$

Observación crucial: el logaritmo es **cóncavo** ($f'' = -1/S^2 < 0$), y por tanto la corrección de Itô es **negativa** ($-\frac{1}{2}\sigma^2$). Esto es el **volatility drag**: la volatilidad reduce el crecimiento efectivo del logaritmo del precio.

Integración de 0 a t:

$$\ln S_t - \ln S_0 = \left(\mu - \frac{1}{2}\sigma^2\right)t + \sigma W_t$$

Exponenciando:

$$S_t = S_0 \cdot \exp\left[\left(\mu - \frac{1}{2}\sigma^2\right)t + \sigma W_t\right]$$

Propiedades de la solución: - $S_t > 0$ siempre (la exponencial es positiva) → consistente con un precio. - $\ln(S_t/S_0) \sim N((\mu - \frac{1}{2}\sigma^2)t, \sigma^2 t)$ → los retornos logarítmicos son normales. - $E[S_t] = S_0 \exp(\mu t)$, pero la mediana es $S_0 \exp((\mu - \frac{1}{2}\sigma^2)t) < E[S_t]$. La distribución es log-normal con cola derecha.

3.5 Conexión con el mercado real

Las desviaciones entre el GBM simulado y los precios reales revelarán:

- **Colas pesadas (fat tails):** eventos extremos más frecuentes que la normal. Se cuantifica via curtosis.
- **Clustering de volatilidad:** la volatilidad no es constante; períodos de alta volatilidad se agrupan. GARCH(1,1) y Heston capturan esto.
- **Asimetría (skewness):** las caídas son más abruptas que las subidas → skewness negativa.
- **Memoria a largo plazo:** el exponente de Hurst H detecta persistencia ($H > 0.5$), anti-persistencia ($H < 0.5$) o browniano puro ($H = 0.5$).

4. CONCLUSIONES ESPERADAS

1. **El GBM captura la estructura de primer orden:** la tendencia (μ) y escala de fluctuación (σ) son reproducibles. Las trayectorias simuladas serán visualmente similares a las reales.
2. **Los retornos reales rechazarán normalidad:** Jarque-Bera y Anderson-Darling producirán p-values significativos por leptocurtosis.
3. **Clustering de volatilidad detectable:** Ljung-Box sobre r^2 y ARCH-LM confirmarán heterocedasticidad → GARCH justificado.
4. **Hurst revelará desviaciones del browniano puro:** $H \neq 0.5$ en la mayoría de activos indica que la EMH en forma fuerte no se sostiene completamente.
5. **El lema de Itô es indispensable:** sin la corrección $-\frac{1}{2}\sigma^2$, la estimación de μ estaría sesgada y las simulaciones sobreestimarían sistemáticamente el precio final.